

PROJETO INTEGRADOR DE PROGRAMAÇÃO

Relatório de Atividades Desenvolvidas

João Pedro da Rosa
Rafael Dziurza

Relatório de Projeto apresentado à Universidade Estadual do Centro-Oeste – Unicentro/Cedeteg, como quesito para conclusão do 1º semestre do Curso de Tecnologia em Big Data no Agronegócio na disciplina de Projeto Integrador ministrada pela professora Luara Peterlini.

Guarapuava
2026

Introdução

Nosso projeto é baseado no terceiro tema proposto pelo Desafio Agrária, “Mapa Nacional de Produção Agrícola por Cultura”. Escolhemos esse tema por entendermos a importância da agricultura para a economia brasileira e também local, junto da necessidade de transformar grandes volumes de dados em informações úteis para apoiar a tomada de decisões.

Identificamos que um dos principais desafios enfrentados por empresas, cooperativas e indústrias do agronegócio é a grande quantidade de dados disponíveis e a dificuldade de organizá-los e apresentá-los de forma clara e acessível ao público. Embora existam diversas bases públicas com informações sobre produção agrícola, esses dados geralmente estão distribuídos em diferentes formatos e estruturas, dificultando análises mais completas e a identificação de padrões relevantes.

Ao longo do projeto, buscamos coletar, organizar, tratar e padronizar dados agrícolas provenientes de fontes confiáveis, como o IBGE e o DERAL. Nosso estudo teve foco em culturas de grande importância para a região de Guarapuava, incluindo milho, soja, trigo, feijão, cebola, cevada, centeio, batata e aveia. Além disso, trabalhamos com informações relacionadas à quantidade produzida, área total plantada e área total colhida dessas culturas.

Também procuramos compreender como esses dados se relacionam em diferentes escalas, tanto no contexto regional quanto nacional. Para isso, desenvolvemos uma base de dados padronizada e um dashboard interativo capaz de apresentar visualmente a evolução da produção agrícola ao longo dos anos, permitindo comparações entre culturas, regiões e períodos, além de dados climáticos trazendo maior relação entre essas informações e nos permitindo gerar insights para a cooperativa.

1. Objetivos

1.1 Objetivo Geral

Nosso principal objetivo foi desenvolver uma base de dados padronizada e um painel interativo capaz de apresentar a distribuição geográfica e a evolução temporal da produção agrícola brasileira. Por meio desse trabalho, buscamos organizar e transformar dados públicos em informações claras e acessíveis, permitindo a análise de diferentes culturas e regiões.

1.2 Objetivos Específicos

- Coletar dados públicos sobre produção agrícola disponibilizados por órgãos oficiais.
- Organizar e padronizar informações provenientes de diferentes fontes.
- Aplicar técnicas de limpeza e transformação de dados utilizando Python.
- Utilizar a biblioteca Pandas para manipulação e análise dos dados.
- Desenvolver habilidades em análise e visualização de dados.
- Criar dashboards interativos utilizando Power BI.
- Aplicar metodologias ágeis para organização das atividades da equipe.
- Utilizar ferramentas de gestão de projetos, como Jira.
- Aprimorar conhecimentos em tratamento de dados geográficos e estatísticos.
- Desenvolver competências relacionadas ao trabalho em equipe e gestão de projetos.

2. Metodologia

Para desenvolver o projeto, organizamos nossas atividades utilizando uma metodologia baseada em sprints, permitindo dividir o trabalho em etapas menores e acompanhar a evolução do projeto de forma mais eficiente.

Planejamento do Projeto

- Definimos o problema que seria abordado.
- Estabelecemos os objetivos do projeto.
- Seleccionamos as fontes de dados que seriam utilizadas.
- Escolhemos as ferramentas necessárias para o desenvolvimento.

Levantamento das Fontes de Dados

- Identificamos e estudamos as bases de dados disponibilizadas pelo IBGE, DERAL e INMET.
- Avaliamos quais informações seriam relevantes para as análises propostas.
- Definimos as culturas agrícolas que fariam parte do estudo.

Coleta dos Dados

- Realizamos a coleta dos dados agrícolas referentes às culturas selecionadas.
- Organizamos os arquivos obtidos em planilhas para facilitar o processamento posterior.

Limpeza e Padronização dos Dados

- Removemos informações desnecessárias e inconsistências presentes nas bases.
- Reorganizamos tabelas que estavam em formatos inadequados para análise.
- Padronizamos nomes de colunas e variáveis.
- Separamos informações como ano, cultura e unidade federativa em campos independentes.

Tratamento dos Dados

- Utilizamos a linguagem Python e a biblioteca Pandas para manipulação dos dados.
- Transformamos os dados para formatos mais adequados.
- Aplicamos técnicas de organização e estruturação das informações.
- Geramos uma base de dados limpa e padronizada.

Análise dos Dados

- Realizamos análises para identificar padrões e tendências.
- Comparamos diferentes culturas agrícolas ao longo dos anos.
- Avaliamos informações em escala regional e nacional.

Desenvolvimento do Dashboard

- Utilizamos o Power Bi e Lovable para criar dashboards interativos.
- Construimos gráficos, filtros e visualizações que facilitam a interpretação dos dados.
- Organizamos os painéis de forma intuitiva para os usuários.

Gestão e Acompanhamento do Projeto

- Utilizamos o Jira para organizar tarefas e acompanhar o progresso da equipe.
- Distribuímos responsabilidades entre os integrantes do grupo.
- Realizamos reuniões periódicas para discutir resultados, solucionar dificuldades e garantir o cumprimento dos prazos estabelecidos.

Por meio dessas etapas, conseguimos transformar dados brutos em informações organizadas e visualmente acessíveis, atingindo os objetivos propostos para o projeto.

3. Desenvolvimento

O nosso projeto foi desenvolvido em três sprints como dito anteriormente, seguindo uma estrutura que evoluía com o passar das etapas.

Sprint 1 – Planejamento e Definição do Projeto

Durante a primeira sprint realizamos as atividades relacionadas ao planejamento geral do projeto.

As principais atividades desenvolvidas foram:

- Definição do problema;
- Definição dos objetivos;
- Escolha das fontes de dados;
- Seleção das ferramentas;
- Organização das tarefas da equipe;
- Construção dos primeiros cronogramas;
- Estruturação inicial do projeto.

Nessa fase foi identificado que os dados agrícolas existentes possuíam potencial para gerar análises relevantes, porém necessitavam de tratamento e organização para se tornarem úteis.

Sprint 2 – Coleta e Tratamento dos Dados

A segunda sprint concentrou-se na parte prática do projeto.

Coletamos dados referentes ao período de 2001 a 2024, abrangendo culturas como:

- Aveia;
- Batata;
- Cebola;
- Centeio;

- Cevada;
- Feijão;
- Milho;
- Soja;
- Trigo.

Além disso, fizemos uma análise da microrregião de Guarapuava.

Os dados coletados apresentavam diversos problemas estruturais, entre eles:

- Excesso de colunas;
- Cabeçalhos complexos;
- Organização em formato de matriz;
- Dificuldade de filtragem;
- Falta de padronização.

Para solucionar esses problemas desenvolvemos um processo de transformação utilizando Python e Pandas.

As principais etapas do código foram:

Leitura da planilha

Inicialmente foi realizada a leitura dos arquivos contendo os dados brutos.

Figura 1 – Lendo a planilha.

```
1 import pandas as pd
2
3 df = pd.read_excel("sec21.xlsx", header=None)
4 #Header=None pois o cabeçalho ocupa a tabela inteira
```

Fonte: autoria própria.

Remoção e renomeação dos cabeçalhos

Foram eliminadas linhas e colunas que não continham informações relevantes para a análise, além de reorganizar e padronizar os dados.

Figura 2 – Retirando o cabeçalho.

```
1 import pandas as pd
2
3 df = pd.read_excel("sec21.xlsx", header=None)
4
5 anos = df.iloc[3]
6 culturas = df.iloc[4]
```

Fonte: autoria própria.

Renomeação das colunas

Foram criados nomes padronizados para todas as colunas da base.

Figura 3 – Renomeando colunas.

```
1 import pandas as pd
2
3 df = pd.read_excel("sec21.xlsx", header=None)
4
5 anos = df.iloc[3]
6 culturas = df.iloc[4]
7
8 novas_colunas = []
9
10 for ano, cultura in zip(anos, culturas):
11
12     if pd.isna(ano) and pd.isna(cultura):
13         novas_colunas.append(f"ano_{cultura}")
14
15     else:
16         novas_colunas.append(cultura)
```

Fonte: autoria própria.

Figura 4 – Removendo linhas.

```
1 dados = df.iloc[5:].copy()
2 dados.columns = novas_colunas
3
4 dados.rename(
5     columns={"Unidade da Federação": "Uf"},
6     inplace=True
7 )
```

Fonte: autoria própria.

Transformação para formato longo

Utilizou-se a função Melt da biblioteca Pandas para transformar a estrutura dos dados, facilitando análises futuras.

Figura 5 – Transformando dados.

```
1 dados_long = dados.melt(
2     id_vars=["Uf"],
3     var_name="Ano_Cultura",
4     value_name="Area plantada"
5 )
```

Fonte: autoria própria.

Separação das informações

As informações de ano e cultura foram separadas em colunas independentes por meio da função Split.

Figura 7 – Separando informações.

```
1 dados_long[["Ano","Cultura"]] = (
2     dados_long["Ano_Cultura"]
3     .str.split("_", expand=True)
4 )
```

Fonte: autoria própria.

Após essas etapas foram obtidos os chamados dados limpos e posteriormente os dados padronizados, prontos para utilização em ferramentas de análise.

Figura 8 – Estrutura inicial padronizada.

PS C:\Users\joao\Desktop\Faculdade\Projeto Integrador\PROJETO AGRÁRIA\Codes VSCODE> & "C:\Program Files\Python314\python.exe" "C:\Users\joao\Desktop\Faculdade\Projeto Integrador\PROJETO AGRÁRIA\Codes VSCODE\teste2.py"

0	1	2	3	4	...	236	237	238	239	240
0 Tabela 1612 - Área plantada, área colhida, qua...	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
1 Variável - Área plantada (Hectares)	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
2 Unidade da Federação	Ano x Produto das lavouras temporárias	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
3 NaN	2001	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
4 NaN	Total Aveia (em grão)	Batata-inglesa	Cebola	...	Cevada (em grão)	Feijão (em grão)	Milho (em grão)	Soja (em grão)	Trigo (em grão)	
5 Rondônia	283728	-	-	-	...	-	2802	349695	643639	-
6 Acre	91952	-	-	-	...	-	5139	37625	17578	-
7 Amazonas	147991	-	-	-	...	-	856	6147	24472	-
8 Roraima	29994	-	-	-	...	-	2345	18158	117215	-
9 Pará	946898	-	-	-	...	-	21374	477962	1194024	-

Fonte: autoria própria.

Sprint 3 – Dashboard e Entrega Final

Na etapa final desenvolvemos os dashboards interativos utilizando Power BI e o Lovable.


O painel foi projetado para permitir:

- Visualização da produção agrícola por região;
- Comparação entre culturas;

- Análise temporal da produção;
- Aplicação de filtros por período;
- Exploração dos dados de forma dinâmica.
- Gerar insights e comparações climáticas.

Dashboard na prática:

Figura 9 – Página inicial do PowerBI.



Fonte: autoria própria.

Nessa imagem podemos ver nossa dashboard interativa rodando no PowerBI, nela conseguimos realizar comparações entre anos, cultivares e informações como: soma de área plantada, soma de área colhida e diversas outras, além de conseguir gerar gráficos interativos para comparação de municípios e estados do Brasil, possibilitando que com poucos clique o usuário visualize exatamente o que ele deseja.


Figura 10 – Dashboard no lovable.



Fonte: autoria própria.

A figura 10 traz nossa Dashboard usando o lovable, nela conseguimos criar uma interface muito mais agradável e fácil de usar, com efeitos de comparação muito mais acessíveis, logo de cara o usuário consegue filtrar o ano que deseja, o tipo de cultura que quer ver a evolução e a própria plataforma já entrega comparativos de anos, área plantada, valores de produção e muito mais, ainda gerando um ranking de estados produtores e mostrando o estado que teve maior produção.


Figura 11 – Mapa do Paraná.



Fonte: autoria própria.

Na figura 11 temos mais uma página de nossa Dashboard, essa sendo voltada para a região de Guarapuava, onde os dados foram colhidos de maneira mais micro e detalhadas, aqui conseguimos gerar informações mais detalhadas de produção dos municípios que pertencem a região.

Figura 12 – Insight climático.



Fonte: autoria própria.

Nessa figura 12 vemos a ultima atualização da nossa dashboard, onde cruzamos dados climáticos o que nos permitiu criar insights de produção, batendo informações como o aumento de produtividade do milho está diretamente ligado aos níveis de precipitação acumulado.

4. Resultados e discussão

Os objetivos propostos foram parcialmente atingidos com sucesso. A nossa equipe conseguiu coletar, organizar, tratar e padronizar os dados provenientes de diferentes fontes, criando uma estrutura adequada para análises futuras.

O dashboard desenvolvido permitiu visualizar a evolução da produção agrícola brasileira de maneira clara e intuitiva, facilitando a identificação de padrões e tendências e permitindo com que conseguimos criar insights poderosos.

Pontos Fortes

- Utilização de dados reais e públicos;
- Processo estruturado de limpeza e padronização;
- Aplicação prática de conceitos de programação e análise de dados;
- Dashboard interativo de fácil utilização;
- Uso de metodologias ágeis para organização da equipe.

Pontos Fracos

- Grande volume de dados exigindo elevado esforço de tratamento;
- Coleta manual de parte das informações;
- Uma certa falta de gestão de tempo para aprofundamento das análises;
- Dependência da qualidade dos dados disponibilizados pelas fontes escolhidas.

Melhorias Futuras

Como possíveis evoluções do nosso projeto pensamos em:

- Automatizar a coleta dos dados;
- Criar uma projeção de produtividade até o ano de 2030;
- Incluir dados climáticos e econômicos;

- Expandir as análises para outras culturas agrícolas;

Matriz de habilidades.

Figura 13 – Matriz final

Personnel	Python	HTML	CSS	JavaScript	XML	Uso de APIs	Agronegócio/Industria	Total	
João Pedro	4	2	2	4	5	2	3	22	
Rafael	4	3	2	3	4	2	3	21	
Media por habilidade	4	0	2	3,5	4,5	2	3		Média por integrante

Fonte: autoria própria

Nossa última avaliação da matriz de habilidades ficou assim, conseguimos notar nossa evolução principalmente na linguagem de programação Python, no início a dificuldade era grande, porém com trabalho e equipe e curiosidade conseguimos chegar em um nível muito satisfatório, conseguindo resolver grande parte do desafio sem auxílios externos, nos demais tópicos também tivemos bastante evolução, inclusive no assunto que se diz respeito ao agronegócio, assunto que era meio desconhecido porém agora já se tornou mais tangível.

5. Referências Bibliográficas

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). Pesquisa Agrícola Municipal (PAM). Rio de Janeiro: IBGE, 2026.

DEPARTAMENTO DE ECONOMIA RURAL (DERAL). Banco de Dados da Produção Agrícola. Curitiba: Secretaria da Agricultura e do Abastecimento do Paraná, 2026.

INSTITUTO NACIONAL DE METEOROLOGIA (INMET). Base de Dados Meteorológicos. Brasília: INMET, 2026.

MCKINNEY, Wes. Python for Data Analysis. 3. ed. Sebastopol: O'Reilly Media, 2022.

MICROSOFT. Power BI Documentation. Microsoft Learn, 2026.

PANDAS DEVELOPMENT TEAM. Pandas Documentation. 2026. Disponível em: <https://pandas.pydata.org>. Acesso em: 23 jun. 2026.

APÊNDICES

A.1. Matrizes de habilidades

Figura 13 – Matriz inicial.

Personnel	Python	HTML	CSS	JavaScript	XML	Uso de APIs	Agronegócio/Industria	Total	
João Pedro	1	1	1	1	2	0	1	7	
Rafael	1	1	2	1	1	0	1	7	
Media por habilidade	1	0	1,5	1	1,5	0	1		Média por integrante

Fonte: autoria própria.

Figura 14 – Matriz final.

Personnel	Python	HTML	CSS	JavaScript	XML	Uso de APIs	Agronegócio/Industria	Total	
João Pedro	4	2	2	4	5	2	3	22	
Rafael	4	3	2	3	4	2	3	21	
Media por habilidade	4	0	2	3,5	4,5	2	3		Média por integrante

Fonte: autoria própria.